DAG Airflow — etl_excel_to_postgres (2 tâches orchestrées, 4 étapes logiques)

Tâche 1 — run_excel_etl

extract_excels()

transform_data()

load_dataframe()

dépendance Airflow (etl_task >> embeddings_task)

Tâche 2 — generate_embeddings (run_cleaning())

3 sous-étapes internes séquentielles, exécutées en mémoire dans un seul worker Python (run_etl()). Non instrumentées séparément par Airflow : pas de retry ni de checkpoint XCom par étape.

écrit les embeddings

transport_embeddings (pgvector, 384 dims)

Ne reçoit pas le DataFrame de la Tâche 1 : re-interroge PostgreSQL de façon autonome. La frontière entre les deux tâches est la persistance en base, pas un échange XCom.

relit transactions (nouvelle requête SQL, aucun XCom)

écrit les tables métier

PostgreSQL camions · transactions · bons_livraison · produits